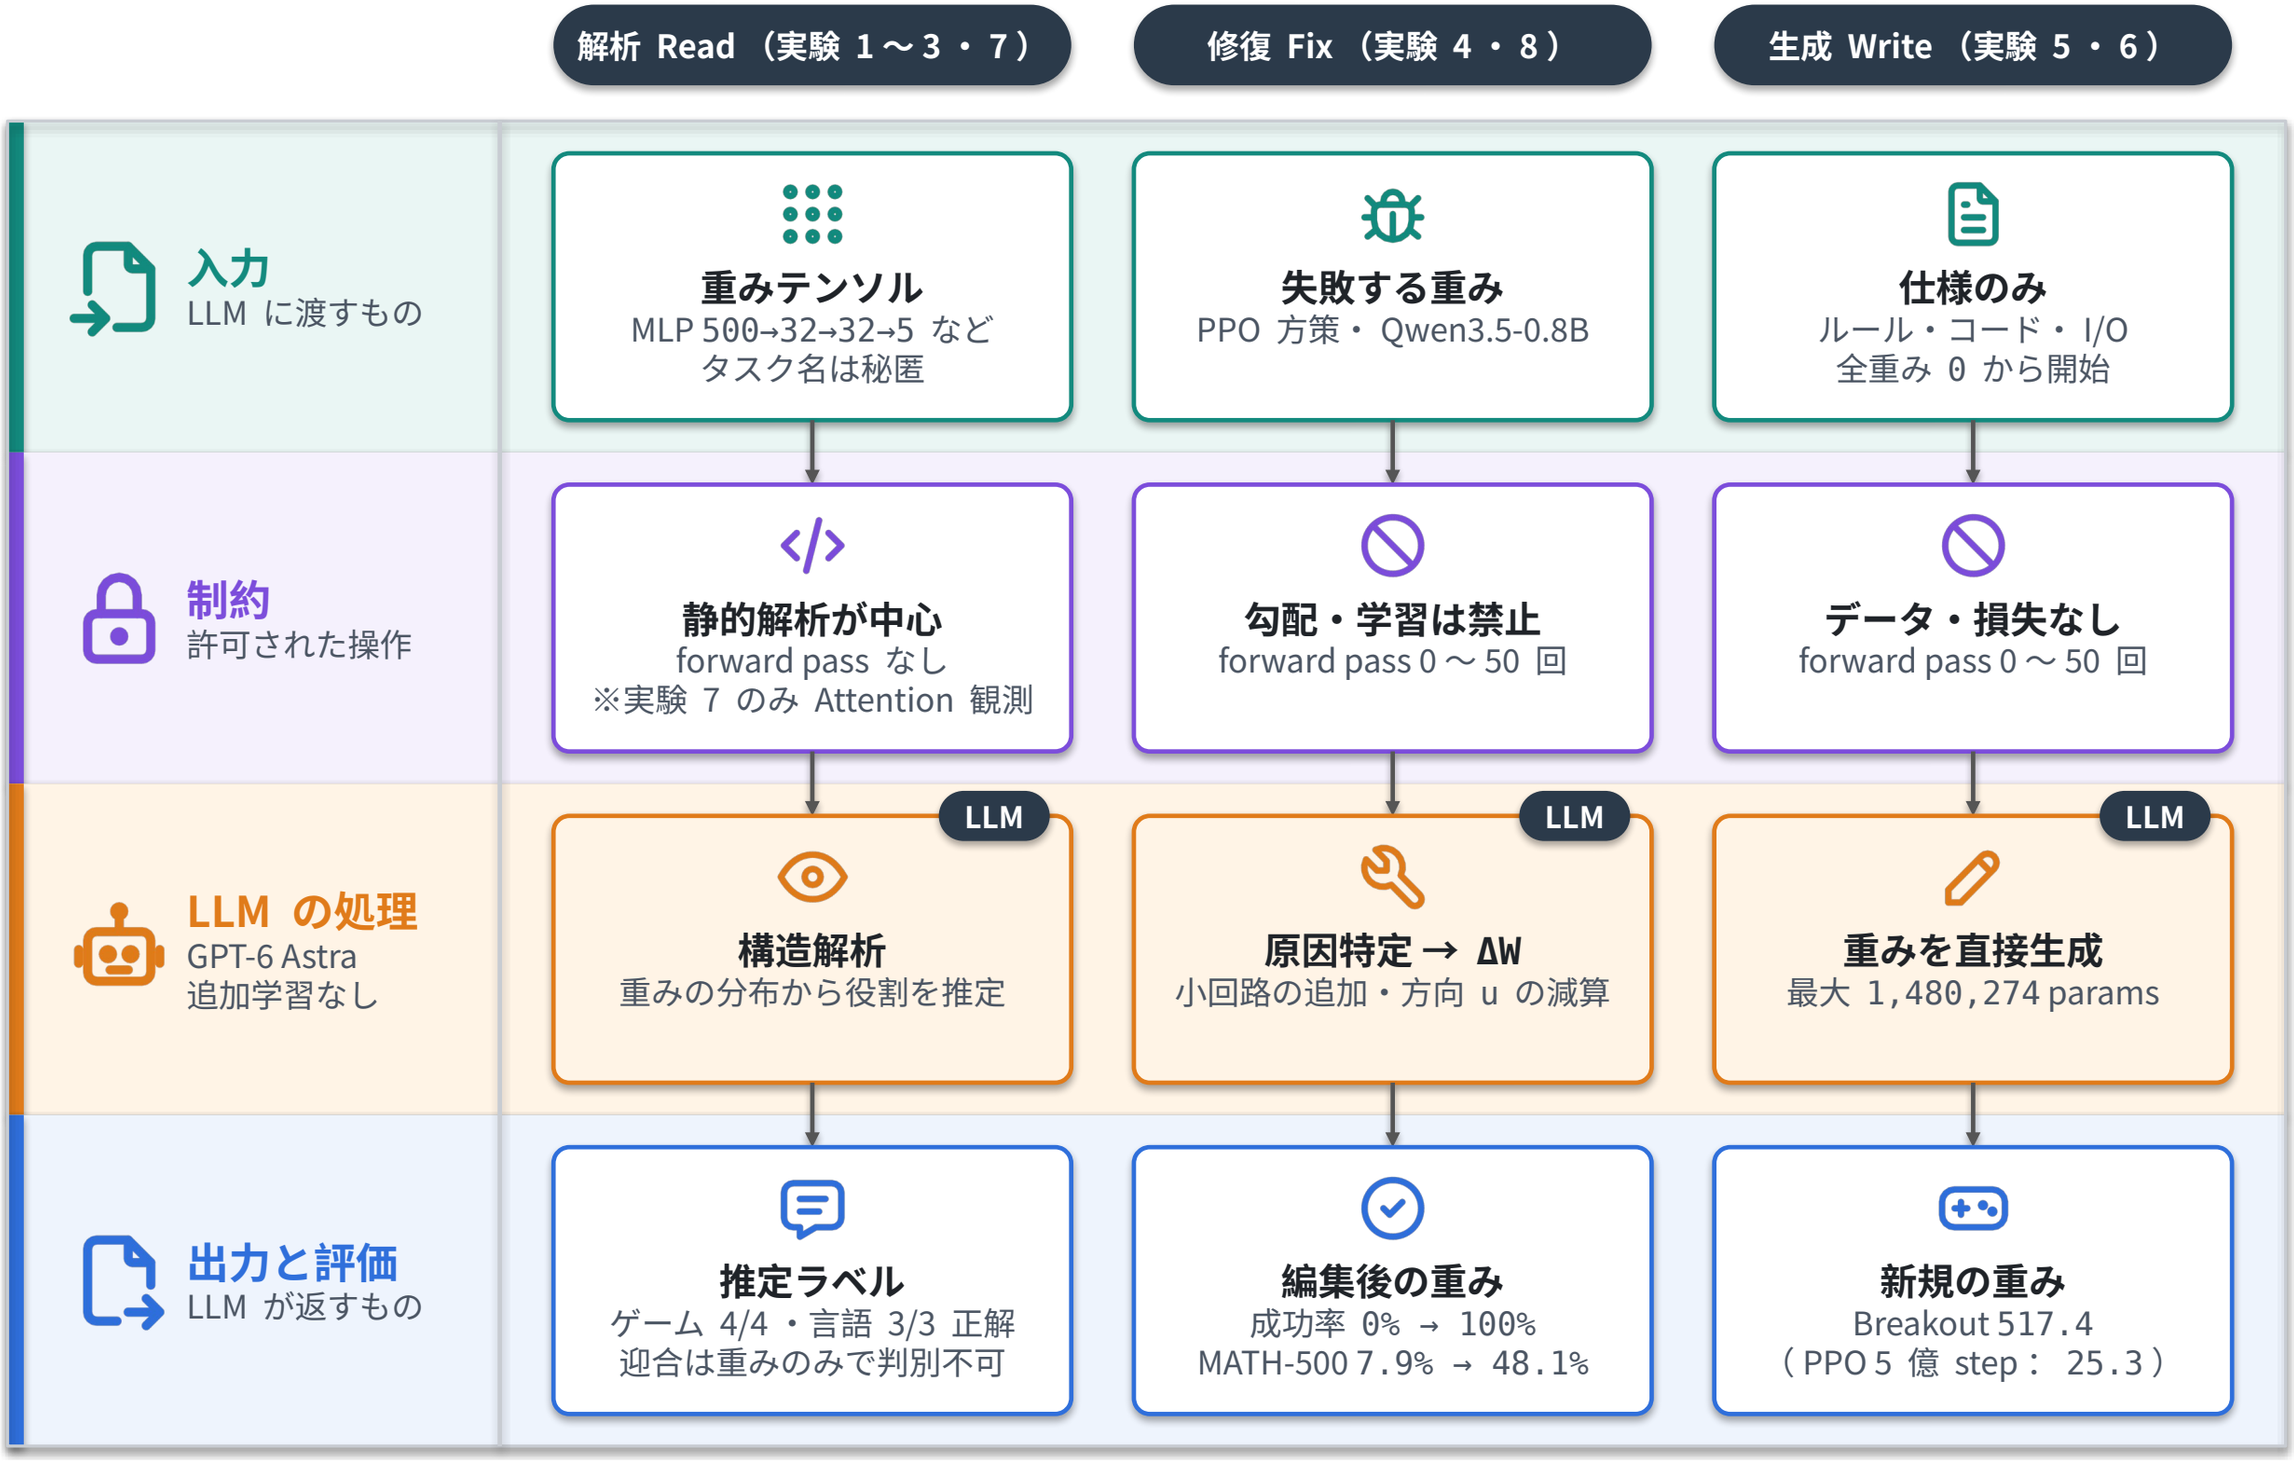

解析 Read （実験 1〜3・7）
修復 Fix （実験 4・8）
生成 Write （実験 5・6）
入力
LLM に渡すもの
重みテンソル
MLP 500→32→32→5 など
タスク名は秘匿
失敗する重み
PPO 方策・ Qwen3.5-0.8B
仕様のみ
ルール・コード・ I/O
全重み 0 から開始
制約
許可された操作
静的解析が中心
forward pass なし
※実験 7 のみ Attention 観測
勾配・学習は禁止
forward pass 0 〜 50 回
データ・損失なし
forward pass 0 〜 50 回
LLM の処理
GPT-6 Astra
追加学習なし
LLM
構造解析
重みの分布から役割を推定
LLM
原因特定 → ΔW
小回路の追加・方向 u の減算
LLM
重みを直接生成
最大 1,480,274 params
出力と評価
LLM が返すもの
推定ラベル
ゲーム 4/4 ・言語 3/3 正解
迎合は重みのみで判別不可
編集後の重み
成功率 0% → 100%
MATH-500 7.9% → 48.1%
新規の重み
Breakout 517.4
（PPO 5 億 step： 25.3）