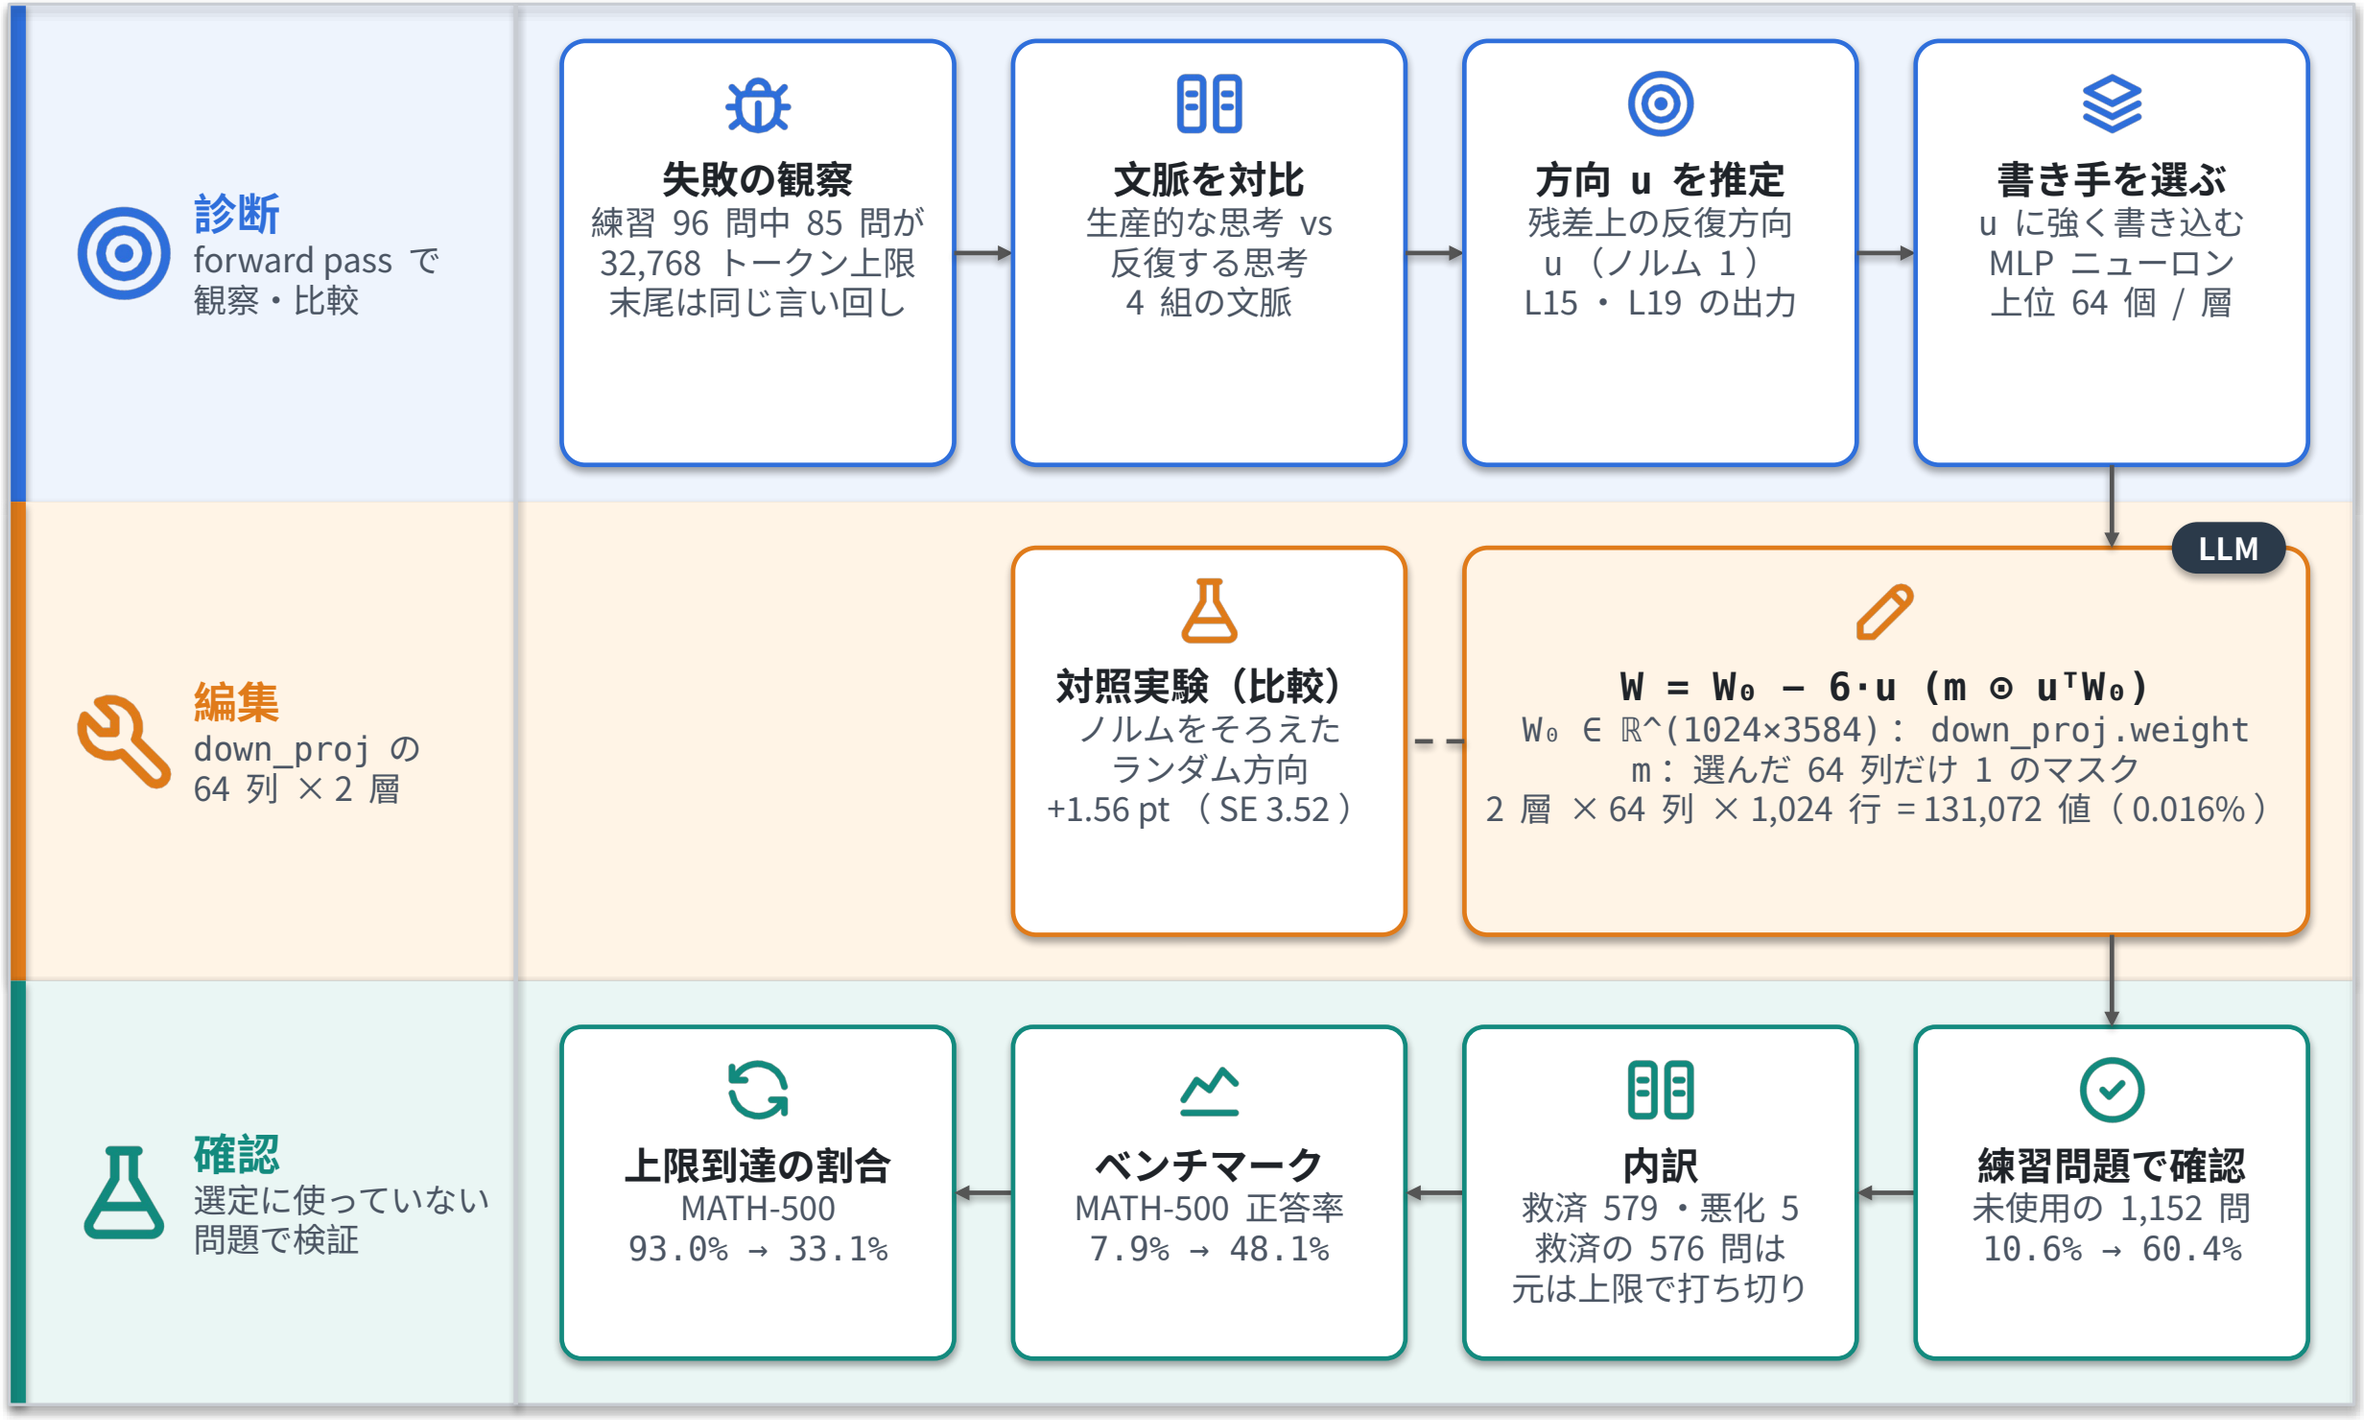

診断
forward pass で
観察・比較
失敗の観察
練習 96 問中 85 問が
32,768 トークン上限
末尾は同じ言い回し
文脈を対比
生産的な思考 vs
反復する思考
4 組の文脈
方向 u を推定
残差上の反復方向
u（ノルム 1）
L15 ・ L19 の出力
書き手を選ぶ
u に強く書き込む
MLP ニューロン
上位 64 個 / 層
LLM
編集
down_proj の
64 列 × 2 層
対照実験（比較）
ノルムをそろえた
ランダム方向
+1.56 pt （ SE 3.52 ）
W = W₀ − 6·u (m ⊙ uᵀW₀)
W₀ ∈ ℝ^(1024×3584)： down_proj.weight
m： 選んだ 64 列だけ 1 のマスク
2 層 × 64 列 × 1,024 行 = 131,072 値（ 0.016% ）
確認
選定に使っていない
問題で検証
上限到達の割合
MATH-500
93.0% → 33.1%
ベンチマーク
MATH-500 正答率
7.9% → 48.1%
内訳
救済 579 ・悪化 5
救済の 576 問は
元は上限で打ち切り
練習問題で確認
未使用の 1,152 問
10.6% → 60.4%